

# NLTK

- Biblioteca de ferramentas úteis para a utilização dos princípios de PLN
- Linguagem Python
- Funcionalidades para manipulação de strings
- Interfaces padrões para realizar tarefas como etiquetar textos, frequência de palavras, lematização e stemmização de palavras, entre vários outros.
- <http://www.nltk.org/index.html>

# NLTK - INSTALAÇÃO

- Requer pelo menos a **versão 3.6** do Python
  - *pip install nltk*
- Linux, MacOS e Windows 32-bit
  - Para instalação no Windows 64-bit, seguir [esse tutorial](#).
- Deu certo? Testar com o comando **import nltk**.


```
>>> import nltk  
>>> |
```

- Após a instalação do *toolkit*, instalar os dados necessários para o funcionamento.
  - NLTK data

# NLTK - INSTALAÇÃO

- Verificar quais pacotes estão desatualizados e clicar em **Download**.
  - Selecionar o identificador **all** e clicar em **Download**.


```
>>> import nltk  
>>> nltk.download()  
showing info https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml
```



# NLTK - INSTALAÇÃO

- A barra de progresso abaixo da janela mostra o andamento do processo.


```
>>> import nltk  
>>> nltk.download()  
showing info https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml
```



# NLTK - INSTALAÇÃO

- A atualização demora por volta de **1 minuto e meio**. Quando estiver tudo certo, todos os pacotes estarão com a cor verde.

```
>>> import nltk  
>>> nltk.download()  
showing info https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml
```



# NLTK - USO

- Dentro do NLTK contém vários córpus
  - Úteis para os etiquetadores, entidades nomeadas, estruturas sintáticas e várias outras funcionalidades.

Corpus	Compiler	Contents
Brown Corpus	Francis, Kucera	15 genres, 1.15M words, tagged, categorized
CESS Treebanks	CLiC-UB	1M words, tagged and parsed (Catalan, Spanish)
Chat-80 Data Files	Pereira & Warren	World Geographic Database
CMU Pronouncing Dictionary	CMU	127k entries
CoNLL 2000 Chunking Data	CoNLL	270k words, tagged and chunked
CoNLL 2002 Named Entity	CoNLL	700k words, pos- and named-entity-tagged (Dutch, Spanish)
CoNLL 2007 Dependency Treebanks (sel)	CoNLL	150k words, dependency parsed (Basque, Catalan)
Dependency Treebank	Narad	Dependency parsed version of Penn Treebank sample
FrameNet	Fillmore, Baker et al	10k word senses, 170k manually annotated sentences
Floresta Treebank	Diana Santos et al	9k sentences, tagged and parsed (Portuguese)
Gazetteer Lists	Various	Lists of cities and countries
Genesis Corpus	Misc web sources	6 texts, 200k words, 6 languages
Gutenberg (selections)	Hart, Newby, et al	18 texts, 2M words
Inaugural Address Corpus	CSpan	US Presidential Inaugural Addresses (1789-present)
Indian POS-Tagged Corpus	Kumaran et al	60k words, tagged (Bangla, Hindi, Marathi, Telugu)
MacMorpho Corpus	NILC, USP, Brazil	1M words, tagged (Brazilian Portuguese)
Movie Reviews	Pang, Lee	2k movie reviews with sentiment polarity classification
Names Corpus	Kantrowitz, Ross	8k male and female names
NIST 1999 Info Extr (selections)	Garofolo	63k words, newswire and named-entity SGML markup
Nombank	Meyers	115k propositions, 1400 noun frames
NPS Chat Corpus	Forsyth, Martell	10k IM chat posts, POS-tagged and dialogue-act tagged

Disponível em <https://www.nltk.org/book/ch02.html>

# NLTK - USO

## ○ Dentro do NLTK contém vários córpus

- Úteis para os etiquetadores, entidades nomeadas, estruturas sintáticas e várias outras funcionalidades.

```
>>> nltk.corpus.mac_morpho.words()
['Jersei', 'atinge', 'média', 'de', 'Cr$', '1,4', ...]
>>> nltk.corpus.mac_morpho.sents()
[['Jersei', 'atinge', 'média', 'de', 'Cr$', '1,4', 'milhão', 'em', 'a', 'venda', 'de', 'a', 'Pinhal', 'em', 'São', 'Paulo'], ['Programe', 'sua', 'viagem', 'a', 'a', 'Exposição', 'Nacional', 'do', 'Zebu', ',', 'que', 'começa', 'dia', '25'], ...]
>>> nltk.corpus.mac_morpho.tagged_words()
[('Jersei', 'N'), ('atinge', 'V'), ('média', 'N'), ...]
>>> nltk.corpus.mac_morpho.tagged_sents()
[[('Jersei', 'N'), ('atinge', 'V'), ('média', 'N'), ('de', 'PREP'), ('Cr$', 'CUR'), ('1,4', 'NUM'), ('milhão', 'N'), ('em', 'PREP|+'), ('a', 'ART'), ('venda', 'N'), ('de', 'PREP|+'), ('a', 'ART'), ('Pinhal', 'NPROP'), ('em', 'PREP'), ('São', 'NPROP'), ('Paulo', 'NPROP')], [('Programe', 'V'), ('sua', 'PROADJ'), ('viagem', 'N'), ('a', 'PREP|+'), ('a', 'ART'), ('Exposição', 'NPROP'), ('Nacional', 'NPROP'), ('do', 'NPROP'), ('Zebu', 'NPROP'), (',', ','), ('que', 'PRO-KS-REL'), ('começa', 'V'), ('dia', 'N'), ('25', 'N|AP')], ...]
```

- Veremos como fazer isso para um texto qualquer!

Mac-Morpho: <http://nilc.icmc.usp.br/macmorpho/>

# NLTK - USO

- Nessa aula, vamos ver detalhadamente algumas funções importantes no tratamento de textos com NLTK.
  - Tokenização
  - Frequência/Contagem de palavras
  - *Stopwords*
  - N-gramas
  - Stemmer e Lemma
  - Etiquetadores
- Para testar as funções, utilizaremos esse corpus!

# NLTK - TOKENIZAÇÃO

- Tokenizar = separar as palavras do texto
  - Tipo um **split?**
- Nível linguístico lexical: uma palavra, número ou pontuação agora é um **token**.
- Dado o texto que vai ser tokenizado, basta usar a função **nltk.word\_tokenize(texto)**:

```
>>> import nltk
>>> texto = "O jogador, que está de camisa verde, marcou o gol da vitória!"
>>> nltk.word_tokenize(texto)
['O', 'jogador', ',', 'que', 'está', 'de', 'camisa', 'verde', ',', 'marcou',
 'o', 'gol', 'da', 'vitória', '!']
```

# NLTK - TOKENIZAÇÃO

- O tokenizador do NLTK pode ter algumas variações, como por exemplo, retornar apenas os tokens sem as pontuações:

- Entramos em um novo mundo chamado **expressões regulares**.

```
>>> from nltk.tokenize import RegexpTokenizer  
>>> tokenizer = RegexpTokenizer(r'\w+')  
>>> tokens = tokenizer.tokenize(texto)  
>>> tokens  
['o', 'jogador', 'que', 'está', 'de', 'camisa', 'verde', 'marcou', 'o', 'gol',  
'da', 'vitória']
```

- E se quiséssemos os tokens sem pontuações e numerais?

```
>>> texto = "O jogador, que está com a camisa 10, marcou o gol da vitória!"  
>>> from nltk.tokenize import RegexpTokenizer  
>>> tokenizer = RegexpTokenizer(r'[A-Z]\w+')  
>>> tokens = tokenizer.tokenize(texto)  
>>> tokens  
['O', 'jogador', 'que', 'está', 'com', 'a', 'camisa', 'marcou', 'o', 'gol',  
'da', 'vitória']
```

# NLTK – FREQUÊNCIA/CONTAGEM

- Com a lista de tokens, é possível fazer a contagem de ocorrência de tokens pelo NLTK.
- Uso da classe **FreqDist()**
  - A função **most\_common()** ordena a frequência dos tokens. Pode ser usado um argumento para informar a quantidade de tokens mais comuns.

```
>>> frequencia = nltk.FreqDist(tokens)
>>> frequencia.most_common()
[(',', 6), ('o', 4), ('a', 3), ('de', 2), ('do', 2), ('New', 2), ('e', 2),
('no', 2), ('Super', 2), ('Bowl', 2), ('.', 2), ('uma', 2), ('da', 2), ('hi-
tória', 2), ('Com', 1), ('um', 1), ('passe', 1), ('Eli', 1), ('Manning', 1),
('para', 1), ('Plaxico', 1), ('Burress', 1), ('39', 1), ('segundos', 1),
('fim', 1), ('York', 1), ('Giants', 1), ('anotou', 1), ('touchdown', 1), ('de-
cisivo', 1), ('derrubou', 1), ('favorito', 1), ('England', 1), ('Patriots',
', 1), ('por', 1), ('17', 1), ('14', 1), ('neste', 1), ('domingo', 1), ('em
', 1), ('Glendale', 1), ('XLII', 1), ('O', 1), ('resultado', 1), ('das', 1),
('maiores', 1), ('zebras', 1), ('acabou', 1), ('com', 1), ('temporada', 1),
('perfeita', 1), ('Tom', 1), ('Brady', 1), ('companhia', 1), ('que', 1),
('esperavam', 1), ('fazer', 1), ('ao', 1), ('levantar', 1), ('troféu', 1),
('NFL', 1), ('sem', 1), ('sofrer', 1), ('derrota', 1), ('ano', 1)]
>>> frequencia.most_common(5)
[(',', 6), ('o', 4), ('a', 3), ('de', 2), ('do', 2)]
```

# NLTK – FREQUÊNCIA/CONTAGEM

- É importante notar que os tokens em maiúsculo e minúsculo são considerados diferentes.
- Portanto, caso o objetivo da contagem seja de palavras iguais, por exemplo, é necessário usar as funções `lower()` (ou `upper()`) para normalizar os tokens.
  - Um novo princípio: **list comprehension**

```
>>> frequencia = nltk.FreqDist(w.lower() for w in tokens)
>>> frequencia.most_common()
[(',', 6), ('o', 5), ('a', 3), ('com', 2), ('de', 2), ('do', 2), ('new', 2),
('e', 2), ('no', 2), ('super', 2), ('bowl', 2), ('.', 2), ('uma', 2), ('d',
a', 2), ('história', 2), ('um', 1), ('passe', 1), ('eli', 1), ('manning', 1),
('para', 1), ('plaxico', 1), ('burress', 1), ('39', 1), ('segundos', 1),
('fim', 1), ('york', 1), ('giants', 1), ('anotou', 1), ('touchdown', 1), ('de-
cisivo', 1), ('derrubou', 1), ('favorito', 1), ('england', 1), ('patriots',
1), ('por', 1), ('17', 1), ('14', 1), ('neste', 1), ('domingo', 1), ('em',
1), ('glendale', 1), ('xlii', 1), ('resultado', 1), ('das', 1), ('maio-
res', 1), ('zebras', 1), ('acabou', 1), ('temporada', 1), ('perfeita', 1),
('tom', 1), ('brady', 1), ('companhia', 1), ('que', 1), ('esperavam', 1),
('fa-
zer', 1), ('ao', 1), ('levantar', 1), ('troféu', 1), ('nfl', 1), ('sem', 1),
('sofrer', 1), ('derrota', 1), ('ano', 1)]
```

Mais de list comprehension [aqui](#) e [aqui](#)!

# NLTK - STOPWORDS

- Stopwords são palavras que podem ser consideradas irrelevantes para um certo resultado buscado.
  - Artigos, preposições, conjunções, por exemplo...

```
>>> import nltk
>>> nltk.corpus.stopwords.words('portuguese')
['de', 'a', 'o', 'que', 'e', 'é', 'do', 'da', 'em', 'um', 'para', 'com', 'não', 'u
ma', 'os', 'no', 'se', 'na', 'por', 'mais', 'as', 'dos', 'como', 'mas', 'ao', 'ele
', 'das', 'à', 'seu', 'sua', 'ou', 'quando', 'muito', 'nos', 'já', 'eu', 'também',
'só', 'pelo', 'pela', 'até', 'isso', 'ela', 'entre', 'depois', 'sem', 'mesmo', 'ao
s', 'seus', 'quem', 'nas', 'me', 'esse', 'eles', 'você', 'essa', 'num', 'nem', 'su
as', 'meu', 'ás', 'minha', 'numa', 'pelos', 'elas', 'qual', 'nós', 'lhe', 'deles',
'essas', 'esses', 'pelas', 'este', 'dele', 'tu', 'te', 'vocês', 'vos', 'lhes', 'me
us', 'minhas', 'teu', 'tua', 'teus', 'tuas', 'noso', 'nossa', 'nossos', 'nossas',
'dela', 'delas', 'esta', 'estes', 'estas', 'aquele', 'aqueila', 'aqueles', 'aquelas
', 'isto', 'aquilo', 'estou', 'está', 'estamos', 'estão', 'estive', 'esteve', 'est
ivemos', 'estiveram', 'estava', 'estávamos', 'estavam', 'estivera', 'estivéramos',
'esteja', 'estejamos', 'estejam', 'estivesse', 'estivéssemos', 'estivessem', 'esti
ver', 'estivermos', 'estiverem', 'hei', 'há', 'havemos', 'hão', 'houve', 'houvemos
', 'houveram', 'houvera', 'houvéramos', 'haja', 'hajamos', 'hajam', 'houvesse', 'h
ouvéssemos', 'houvessem', 'houver', 'houvermos', 'houverem', 'houverei', 'houverá'
, 'houveremos', 'houverão', 'houveria', 'houveríamos', 'houveriam', 'sou', 'somos'
, 'são', 'era', 'éramos', 'eram', 'fui', 'foi', 'fomos', 'foram', 'fora', 'fôramos
', 'seja', 'sejamos', 'sejam', 'fosse', 'fôssemos', 'fossem', 'for', 'formos', 'fo
rem', 'serei', 'será', 'seremos', 'serão', 'seria', 'seríamos', 'seriam', 'tenho',
'tem', 'temos', 'tém', 'tinha', 'tínhamos', 'tinham', 'tive', 'teve', 'tivemos',
'tiveram', 'tivera', 'tivéramos', 'tenha', 'tenhamos', 'tenham', 'tivesse', 'tivéss
emos', 'tivessem', 'tiver', 'tivermos', 'tiverem', 'terei', 'terá', 'teremos', 'te
rão', 'teria', 'teríamos', 'teriam']
```

# NLTK - STOPWORDS

- É possível, então, fazer vários tipos de pré-processamento.
  - Exemplo: Frequência dos tokens sem stopwords

```
>>> tokenizer = RegexpTokenizer(r'[A-z]\w*')
>>> tokens = tokenizer.tokenize(texto)
>>> stopwords = nltk.corpus.stopwords.words('portuguese')
>>> tokens_sem_stopwords = [w.lower() for w in tokens if w not in stopwords]
>>> frequencia = nltk.FreqDist(tokens_sem_stopwords)
>>> print(frequencia.most_common())
[('new', 2), ('super', 2), ('bowl', 2), ('história', 2), ('com', 1), ('passe', 1), ('eli', 1), ('manning', 1), ('plaxico', 1), ('burress', 1), ('segundos', 1), ('fim', 1), ('york', 1), ('giants', 1), ('anotou', 1), ('touchdown', 1), ('decisivo', 1), ('derrubou', 1), ('favorito', 1), ('england', 1), ('patriots', 1), ('neste', 1), ('domingo', 1), ('glendale', 1), ('xlii', 1), ('o', 1), ('resultado', 1), ('maiores', 1), ('zebras', 1), ('acabou', 1), ('temporada', 1), ('perfeta', 1), ('tom', 1), ('brady', 1), ('companhia', 1), ('esperavam', 1), ('fazer', 1), ('levantar', 1), ('troféu', 1), ('nfl', 1), ('sofrer', 1), ('derrota', 1), ('ano', 1)]
```

# NLTK – N-GRAMAS

- Com a lista de tokens, é possível ter os n-gramas necessários para qualquer análise.
- Bigramas: **from nltk import bigrams**
- Trigramas: **from nltk import trigrams**
- 4-gram ou mais: **from nltk import ngrams**
  - Um ‘novo’ conceito: importando módulos.

# NLTK – N-GRAMAS

## ○ Bigramas

```
>>> texto = "Com um passe de Eli Manning para Plaxico Burress a 39 segundos do fim, o New York Giants anotou o touchdown decisivo e derrubou o favorito New England Patriots por 17 a 14 neste domingo, em Glendale, no Super Bowl XLII. O resultado, uma das maiores zebras da história do Super Bowl, acabou com a temporada perfeita de Tom Brady e companhia, que esperavam fazer história ao levantar o troféu da NFL sem sofrer uma derrota no ano."  
>>> from nltk import bigrams  
>>> list(bigrams(tokens)) #já com o texto tokenizado  
[('Com', 'um'), ('um', 'passe'), ('passe', 'de'), ('de', 'Eli'), ('Eli', 'Manning'), ('Manning', 'para'), ('para', 'Plaxico'), ('Plaxico', 'Burress'), ('Burress', 'a'), ('a', 'segundos'), ('segundos', 'do'), ('do', 'fim'), ('fim', 'o'), ('o', 'New'), ('New', 'York'), ('York', 'Giants'), ('Giants', 'anotou'), ('anotou', 'o'), ('o', 'touchdown'), ('touchdown', 'decisivo'), ('decisivo', 'e'), ('e', 'derrubou'), ('derrubou', 'o'), ('o', 'favorito'), ('favorito', 'New'), ('New', 'England'), ('England', 'Patriots'), ('Patriots', 'por'), ('por', 'a'), ('a', 'neste'), ('neste', 'domingo'), ('domingo', 'em'), ('em', 'Glendale'), ('Glendale', 'no'), ('no', 'Super'), ('Super', 'Bowl'), ('Bowl', 'XLII'), ('XLII', 'O'), ('O', 'resultado'), ('resultado', 'uma'), ('uma', 'das'), ('das', 'maiores'), ('maiores', 'zebras'), ('zebras', 'da'), ('da', 'história'), ('história', 'do'), ('do', 'Super'), ('Super', 'Bowl'), ('Bowl', 'acabou'), ('acabou', 'com'), ('com', 'a'), ('a', 'temporada'), ('temporada', 'perfeita'), ('perfeita', 'de'), ('de', 'Tom'), ('Tom', 'Brady'), ('Brady', 'e'), ('e', 'companhia'), ('companhia', 'que'), ('que', 'esperavam'), ('esperavam', 'fazer'), ('fazer', 'história'), ('história', 'ao'), ('ao', 'levantar'), ('levantar', 'o'), ('o', 'troféu'), ('troféu', 'da'), ('da', 'NFL'), ('NFL', 'sem'), ('sem', 'sofrer'), ('sofrer', 'uma'), ('uma', 'derrota'), ('derrota', 'no'), ('no', 'ano')]
```

# NLTK – N-GRAMAS

## ○ Trigrams

```
>>> from nltk import trigrams  
>>> list(trigrams(tokens))  
[('Com', 'um', 'passe'), ('um', 'passe', 'de'), ('passe', 'de', 'Eli'), ('de', 'Eli', 'Manning'), ('Eli', 'Manning', 'para'), ('Manning', 'para', 'Plaxico'), ('para', 'Plaxico', 'Burress'), ('Plaxico', 'Burress', 'a'), ('Burress', 'a', 'segundos'), ('a', 'segundos', 'do'), ('segundos', 'do', 'fim'), ('do', 'fim', 'o'), ('fim', 'o', 'New'), ('o', 'New', 'York'), ('New', 'York', 'Giants'), ('York', 'Giants', 'anotou'), ('Giants', 'anotou', 'o'), ('anotou', 'o', 'touchdown'), ('o', 'touchdown', 'decisivo'), ('touchdown', 'decisivo', 'e'), ('decisivo', 'e', 'derrubou'), ('e', 'derrubou', 'o'), ('derrubou', 'o', 'favorito'), ('o', 'favorito', 'New'), ('favorito', 'New', 'England'), ('New', 'England', 'Patriots'), ('England', 'Patriots', 'por'), ('Patriots', 'por', 'a'), ('por', 'a', 'neste'), ('a', 'neste', 'domingo'), ('neste', 'domingo', 'em'), ('domingo', 'em', 'Glendale'), ('em', 'Glendale', 'no'), ('Glendale', 'no', 'Super'), ('no', 'Super', 'Bowl'), ('Super', 'Bowl', 'XLII'), ('Bowl', 'XLII', 'o'), ('XLII', 'o', 'resultado'), ('o', 'resultado', 'uma'), ('resultado', 'uma', 'das'), ('uma', 'das', 'maiores'), ('das', 'maiores', 'zebras'), ('maiores', 'zebras', 'da'), ('zebras', 'da', 'história'), ('da', 'história', 'do'), ('história', 'do', 'Super'), ('do', 'Super', 'Bowl'), ('Super', 'Bowl', ' acabou'), ('Bowl', ' acabou', 'com'), ('acabou', 'com', 'a'), ('com', 'a', 'temporada'), ('a', 'temporada', 'perfeita'), ('temporada', 'perfeita', 'de'), ('perfeita', 'de', 'Tom'), ('de', 'Tom', 'Brady'), ('Tom', 'Brady', 'e'), ('Brady', 'e', 'companhia'), ('e', 'companhia', 'que'), ('companhia', 'que', 'esperavam'), ('que', 'esperavam', 'fazer'), ('esperavam', 'fazer', 'história'), ('fazer', 'história', 'ao'), ('história', 'ao', 'levantar'), ('ao', 'levantar', 'o'), ('levantar', 'o', 'troféu'), ('o', 'troféu', 'da'), ('troféu', 'da', 'NFL'), ('da', 'NFL', 'sem'), ('NFL', 'sem', 'sofrer'), ('sem', 'sofrer', 'uma'), ('sofrer', 'uma', 'derrota'), ('uma', 'derrota', 'no'), ('derrota', 'no', 'ano')]
```

# NLTK – N-GRAMAS

## ○ N-gramas: testando com 4-gram

```
>>> from nltk import ngrams  
>>> list(ngrams(tokens, 4))  
[('Com', 'um', 'passe', 'de'), ('um', 'passe', 'de', 'Eli'), ('passe', 'de', 'Eli', 'Manning'), ('de', 'Eli', 'Manning', 'para'), ('Eli', 'Manning', 'para', 'Plaxico'), ('Manning', 'para', 'Plaxico', 'Burress'), ('para', 'Plaxico', 'Burress', 'a'), ('Plaxico', 'Burress', 'a', 'segundos'), ('Burress', 'a', 'segundos', 'do'), ('a', 'segundos', 'do', 'fim'), ('segundos', 'do', 'fim', 'o'), ('do', 'fim', 'o', 'New'), ('fim', 'o', 'New', 'York'), ('o', 'New', 'York', 'Giants'), ('New', 'York', 'Giants', 'anotou'), ('York', 'Giants', 'anotou', 'o'), ('Giants', 'anotou', 'o', 'touchdown'), ('anotou', 'o', 'touchdown', 'decisivo'), ('o', 'touchdown', 'decisivo', 'e'), ('touchdown', 'decisivo', 'e', 'derrubou'), ('decisivo', 'e', 'derrubou', 'o'), ('e', 'derrubou', 'o', 'favorito'), ('derrubou', 'o', 'favorito', 'New'), ('o', 'favorito', 'New', 'England'), ('favorito', 'New', 'England', 'Patriots'), ('New', 'England', 'Patriots', 'por'), ('England', 'Patriots', 'por', 'a'), ('Patriots', 'por', 'a', 'neste'), ('por', 'a', 'neste', 'domingo'), ('a', 'neste', 'domingo', 'em'), ('neste', 'domingo', 'em', 'Glendale'), ('domingo', 'em', 'Glendale', 'no'), ('em', 'Glendale', 'no', 'Super'), ('Glendale', 'no', 'Super', 'Bowl'), ('no', 'Super', 'Bowl', 'XLII'), ('Super', 'Bowl', 'XLII', 'no')]
```

# NLTK – N-GRAMAS

- Os n-gramas são importantes para várias análises. Um exemplo, no nosso caso, seria conseguir as entidades nomeadas do nosso trecho.

```
35  from nltk import bigrams
36  from nltk import trigrams
37
38  bigramas_lista = list(bigrams(tokens))
39  trigramas_lista = list(trigrams(tokens))
40
41  for info in bigramas_lista:
42      if (info[0][0].isupper() and info[1][0].isupper()):
43          print(info)
44
45  for info in trigramas_lista:
46      if (info[0][0].isupper() and info[1][0].isupper() and info[2][0].isupper()):
47          print(info)
```

---

```
('Eli', 'Manning')
('Plaxico', 'Burress')
('New', 'York')
('York', 'Giants')
('New', 'England')
('England', 'Patriots')
('Super', 'Bowl')
('Bowl', 'XLII')
('XLII', 'O')
('Super', 'Bowl')
('Tom', 'Brady')
('New', 'York', 'Giants')
('New', 'England', 'Patriots')
('Super', 'Bowl', 'XLII')
('Bowl', 'XLII', 'O')
```

# NLTK – STEMMER E LEMMATIZER

- STEMMING: consiste em reduzir a palavra ao seu **radical**.
  - amig: amigo, amiga, amigão
  - gat: gato, gata, gatos
  - **prop: propõem, propuseram, propondo**
- LEMATIZAÇÃO: consiste em reduzir a palavra à sua **forma canônica**, levando em conta sua **classe gramatical**.
  - **propor: propõem, propuseram, propondo**
  - estudar: estudando, estudioso, estudei

## NLTK – STEMMER E LEMMATIZER

- O NLTK tem implementado vários algoritmos de para stemmer:
  - RSLP
  - Porter
  - ISRI
  - Lancaster
  - Snowball

# NLTK – STEMMER E LEMMATIZER

- O NLTK tem implementado várias variantes de stemmers:
  - **RSLP – Removedor de Sufixos da Língua Portuguesa**
    - Porter
    - ISRI
    - Lancaster
    - Snowball

```
>>> import nltk
>>> stemmer = nltk.RSLPStemmer()
>>> stemmer.stem('amigão')
'amig'
>>> stemmer.stem('amigo')
'amig'
>>> stemmer.stem('propuseram')
'propus'
>>> stemmer.stem('propõem')
'propõ'
>>> stemmer.stem('proondo')
'prop'
>>> |
```

# NLTK – STEMMER E LEMMATIZER

- Infelizmente o NLTK ainda **não tem** um lematizador para o Português bom o bastante.
- Tentativa: **WordNet Lemmatizer**
  - Funciona somente para o inglês...
  - Mas fiquem tranquilos, no spaCy tem para o português... =)

```
>>> lemmatizer = nltk.stem.WordNetLemmatizer()
>>> lemmatizer.lemmatize('propõem', pos='v')
'propõem'
>>> lemmatizer.lemmatize('estudei', pos='v')
'estudei'
>>> lemmatizer.lemmatize('propõem', pos='n')
'propõem'
>>> lemmatizer.lemmatize('studied', pos='v')
'study'
>>> lemmatizer.lemmatize('studying', pos='v')
'study'
>>> lemmatizer.lemmatize('sings', pos='v')
'sing'
>>> |
```

## NLTK – ETIQUETADORES

- O NLTK possui **dois corpus** que servem como base para o etiquetador em português: o **Floresta** e o **Mac Morpho**.
  - Para o inglês já existe um etiquetador padrão treinado: o `nltk.pos_tag()`.
- Os etiquetadores passam primeiramente por uma fase de treinamento com as sentenças presentes.
  - Floresta: 9.266 sentenças etiquetadas
  - Mac Morpho: 51.397 sentenças etiquetadas
- Como resultado, os etiquetadores retornam uma tupla ('palavra', 'classe gramatical')
  - Na qual a classe grammatical depende do treinamento que é realizado.

# NLTK – ETIQUETADORES: MAC MORPHO

```
50 from nltk.corpus import mac_morpho
51 from nltk.tag import UnigramTagger
52
53 tokens = nltk.word_tokenize(corpus_teste.read())
54
55 sentencias_treinadoras = mac_morpho.tagged_sents()
56 etiq = UnigramTagger(sentencias_treinadoras)
57 tags = etiq.tag(tokens)
58 print(tags)
59
```

---

```
[('Giants', 'NPROP'), ('batem', 'V'), ('os', 'ART'), ('Patriots', None),
('no', 'KC'), ('Super', 'NPROP'), ('Bowl', 'NPROP'), ('XLII', None),
('Azarões', None), ('acobam', 'VAUX'), ('com', 'PREP'), ('a', 'ART'),
('invencibilidade', 'N'), ('de', 'PREP'), ('New', 'NPROP'), ('England',
'NPROP'), ('e', 'KC'), ('ficam', 'V'), ('com', 'PREP'), ('o', 'ART'),
('título', 'N'), ('da', 'NPROP'), ('temporada', 'N'), ('04/02/2008', None),
('-', '-'), ('01h07m', None), ('-', '-'), ('Atualizado', None), ('em',
'PREP|+'), ('04/02/2008', None), ('-', '-'), ('09h49m', None), ('Com',
'PREP'), ('um', 'ART'), ('passe', 'N'), ('de', 'PREP'), ('Eli', 'NPROP'),
('Manning', 'NPROP'), ('para', 'PREP'), ('Plaxico', None), ('Burress',
None), ('a', 'ART'), ('39', 'NUM'), ('segundos', 'N'), ('do', 'NPROP'),
('fim', 'N'), ('', ', ',''), ('o', 'ART'), ('New', 'NPROP'), ('York', 'NPROP'),
('Giants', 'NPROP'), ('anotou', 'V'), ('o', 'ART'), ('touchdown', 'N|EST'),
```

# NLTK – ETIQUETADORES: MAC MORPHO

```
50 from nltk.corpus import mac_morpho
51 from nltk.tag import UnigramTagger
52
53 tokens = nltk.word_tokenize(corpus_teste.read())
54
55 sentencias_treinadoras = mac_morpho.tagged_sents()
56 etiq = UnigramTagger(sentencias_treinadoras)
57 tags = etiq.tag(tokens)
58 print(tags)
59
```

---

```
[('Giants', 'NPROP'), ('batem', 'V'), ('os', 'ART'), ('Patriots', None),
('no', 'KC'), ('Super', 'NPROP'), ('Bowl', 'NPROP'), ('XLII', None),
('Azarões', None), ('acobam', 'VAUX'), ('com', 'PREP'), ('a', 'ART'),
('invencibilidade', 'N'), ('de', 'PREP'), ('New', 'NPROP'), ('England',
'NPROP'), ('e', 'KC'), ('ficam', 'V'), ('com', 'PREP'), ('o', 'ART'),
('título', 'N'), ('da', 'NPROP'), ('temporada', 'N'), ('04/02/2008', None),
('-', '-'), ('01h07m', None), ('-', '-'), ('Atualizado', None), ('em',
'PREP|+'), ('04/02/2008', None), ('-', '-'), ('09h49m', None), ('Com',
'PREP'), ('um', 'ART'), ('passe', 'N'), ('de', 'PREP'), ('Eli', 'NPROP'),
('Manning', 'NPROP'), ('para', 'PREP'), ('Plaxico', None), ('Burress',
None), ('a', 'ART'), ('39', 'NUM'), ('segundos', 'N'), ('do', 'NPROP'),
('fim', 'N'), ('.', '.', '.'), ('o', 'ART'), ('New', 'NPROP'), ('York', 'NPROP'),
('Giants', 'NPROP'), ('anotou', 'V'), ('o', 'ART'), ('touchdown', 'N|EST'),
```

- Mas e aqueles None ali? O que significam?

## NLTK – ETIQUETADORES: MAC MORPHO

- Por ter de passar por uma **fase de treinamento**, tinham palavras que o etiquetador não conseguiu identificar e fazer a classificação.
- Uma solução é pré-classificar todas as palavras do texto como substantivos (**N**) e depois treinar o etiquetador normalmente.
  - Usa-se o pacote **DefaultTagger**

# NLTK – ETIQUETADORES: MAC MORPHO

```
50 from nltk.corpus import mac_morpho
51 from nltk.tag import DefaultTagger
52 from nltk.tag import UnigramTagger
53
54 tokens = nltk.word_tokenize(corpus_teste.read())
55
56 etiq_padrao = DefaultTagger('N')
57 sentencas_treinadoras = mac_morpho.tagged_sents()
58 etiq = UnigramTagger(sentencas_treinadoras, backoff=etiq_padrao)
59 tags = etiq.tag(tokens)
60 print(tags)
61
```

```
[('Giants', 'NPROP'), ('batem', 'V'), ('os', 'ART'), ('Patriots', 'N'),
('no', 'KC'), ('Super', 'NPROP'), ('Bowl', 'NPROP'), ('XLII', 'N'),
('Azarões', 'N'), ('acabam', 'VAUX'), ('com', 'PREP'), ('a', 'ART'),
('invencibilidade', 'N'), ('de', 'PREP'), ('New', 'NPROP'), ('England',
'NPROP'), ('e', 'KC'), ('ficam', 'V'), ('com', 'PREP'), ('o', 'ART'),
('título', 'N'), ('da', 'NPROP'), ('temporada', 'N'), ('04/02/2008', 'N'),
('-', '-'), ('01h07m', 'N'), ('-', '-'), ('Atualizado', 'N'), ('em',
'PREP|+'), ('04/02/2008', 'N'), ('-', '-'), ('09h49m', 'N'), ('Com',
'PREP'), ('um', 'ART'), ('passe', 'N'), ('de', 'PREP'), ('Eli', 'NPROP'),
('Manning', 'NPROP'), ('para', 'PREP'), ('Plaxico', 'N'), ('Burress', 'N'),
('a', 'ART'), ('39', 'NUM'), ('segundos', 'N'), ('do', 'NPROP'), ('fim',
'N'), ('', ', ', ','), ('o', 'ART'), ('New', 'NPROP'), ('York', 'NPROP'),
('Giants', 'NPROP'), ('anotou', 'V'), ('o', 'ART'), ('touchdown', 'N|EST'),
```

# NLTK – ETIQUETADORES: MAC MORPHO

Classe Gramatical	Etiiqueta	Exemplos
Adjetivo	ADJ	bom - ruim - ótimo - péssimo
Advérbio	ADV	muito - pouco - normalmente
Advérbio Conectivo Subordinativo	ADV-KS	Sei onde mora
Advérbio Relativo Subordinativo	ADV-KS-REL	onde - quando - como o - a - os - as
Artigo	ART	e - nem - mas - ou - pois
Conjunção Coordenativa	KC	que - porque - assim
Conjunção Subordinativa	KS	ufa! - viva! - ai! - oi!
Interjeição	IN	três - quatro - 3 - 4
Numeral	NUM	até - apenas - eis - cá
Palavra Denotativa	PDEN	dormido - espalhado - tido
Particípio	PCP	meu - nosso - este - algum
Pronome Adjetivo	PROADJ	Sei quem chegou
Pronome Conectivo Subordinativo	PRO-KS	o qual - cujo
Pronome Conectivo Subord. Relativo	PRO-KS-REL	eu - me - Vossa Alteza
Pronome Pessoal	PROPESS	isto - isso - aquilo - alguém
Pronome Substantivo	PROSUB	R\$ - US\$
Símbolo de Moeda Corrente	CUR	hotel - quarto - atendimento
Substantivo	N	Maria - Vinícius - Globo
Substantivo Próprio	NPROP	é - foi - gostar - ir
Verbo	V	ter - haver
Verbo Auxiliar	VAUX	

## NLTK – ETIQUETADORES: MAC MORPHO

- É possível, então, fazer várias manipulações com a lista de tuplas resultante:
  - Análises descritivas
  - Análise sintática
  - **Chunking**
    - Reconhecimento de Entidades Nomeadas
      - Nosso problema antigo!!
  - E várias outras...!

# NLTK – ETIQUETADORES: MAC MORPHO

```
71 from nltk.chunk import RegexpParser  
72 pattern = 'NP:{<NPROP><NPROP>|<N><N>}'  
73 analiseGramatical = RegexpParser(pattern)  
74 arvore = analiseGramatical.parse(tags)  
75 print(arvore)  
76 arvore.draw()  
77
```

```
(S  
  Com/PREP  
  um/ART  
  passe/N  
  de/PREP  
  (NP Eli/NPROP Manning/NPROP)  
  para/PREP  
  (NP Plaxico/N Burress/N)  
  a/ART  
  39/NUM  
  segundos/N  
  do/NPROP  
  fim/N
```

# NLTK – TRABALHANDO COM CORPUS

- Faça uma **análise descritiva** completa do nosso corpus de teste, utilizando as funções do NLTK.
- Exemplos de atributos:
  - Quantidade de tokens
  - Quantidade de sentenças / média do tamanho das sentenças
  - Quantidade de substantivos, adjetivos, advérbios...
  - Quantidade de palavras com o mesmo radical
  - Quantidade de símbolos de pontuação
  - Palavras mais frequentes do corpus
  - ...
- Use sua imaginação!!! =D